

特徴量選択による日常的意思決定の個人化後悔予測モデル実装

乾 映之右†

† 武蔵野大学データサイエンス学部 〒135-0063 東京都江東区有明3丁目3-3

E-mail: †s2322007@stu.musashino-u.ac.jp

あらまし 後悔は「選ばなかった選択肢」との比較による反実仮想的思考から生じ、損失回避バイアスにより人々はこれを強く避けようとする。従来の後悔理論研究は投資・医療・キャリアなど大規模な意思決定を対象とし、意思決定支援も事後の振り返りに留まってきた。しかし、日常の小さな意思決定は頻度が高く累積的影響が大きいにもかかわらず、予測的支援は未開拓である。本研究では、意思決定履歴とコンテキスト情報から SHAP 値による適応的特徴量選択を行い、ユーザーごとに異なる後悔要因を抽出する個人化予測モデルを提案する。仮想ユーザーを用いた実験により、提案手法はルールベース手法と比較して MAE を 39%改善し、ユーザー間で平均 23%の特徴量が異なることを確認した。また、提案モデルを Web アプリケーションとして実装し、実用可能性を示した。

キーワード 機械学習, SHAP, 意思決定支援

1 はじめに

1.1 背景

日常生活において、我々は無数の小さな意思決定を行う。ランチで何を食べるか、衝動買いをするべきか、SNS を見続けるべきか。これらの決定は一つ一つは小さいが、毎日数十回繰り返されることで累積的に生活の質に影響する。しかし、疲労やストレスにより判断力が低下している時、我々はしばしば後悔する選択をしてしまう。

例えば、「ストレスが溜まっている時に高額なランチを食べて後悔した」「疲れている時に衝動買いをして後悔した」といった経験は誰にでもあるだろう。このような後悔は、その瞬間の気分や状況により判断力が歪められることで発生する。もし意思決定の瞬間に「あなたは今この選択を後悔する可能性が高い」と警告されれば、より良い選択ができる可能性がある。

1.2 既存研究の限界

後悔理論 (Regret Theory) に関する既存研究 [1] [2] は、主に投資判断、医療選択、キャリア決定など、「人生を変える大きな決定」に焦点を当ててきた。これらの研究は重要だが、頻度の観点では日常の小さな意思決定の方が圧倒的に多い。一方で、日常の小さな意思決定は研究対象として見過ごされてきた。

また、Decision Journal などの既存システム [3] は事後の振り返りに留まり、意思決定時点での予測的な支援を提供していない。これらのシステムは「なぜ後悔したか」を理解する助けにはなるが、「これから後悔するか」を予測することはできない。さらに、既存の推薦システムは「何を好むか」を予測するが、「何を後悔するか」という負の側面は扱わない。

1.3 本研究の貢献

本研究では、以下の3つの独自性を持つシステムを提案する：

(1) 日常的意思決定への特化: 頻度の高い小規模決定に焦点を当て、気分・ストレス・空腹度など日常的コンテキストを

18 次元で記録

(2) 予測型アプローチ: 過去データから意思決定時点で後悔リスクを予測し、事前に警告

(3) 個人化された学習モデル: SHAP 値による適応的特徴量選択により、「あなたが後悔しやすい状況」を特定

2 関連研究

2.1 後悔理論

後悔 (Regret) は意思決定研究において重要な概念である。Zeelenberg ら [1] は、後悔が「選ばなかった選択肢」との比較 (Counterfactual Thinking) で生じることを実証的に示した。彼らの研究によれば、後悔は単なる失望とは異なり、「別の選択をしていれば」という反実仮想的な思考を伴う。

Kahneman and Tversky [2] のプロスペクト理論は、人間が利得よりも損失に敏感であること (損失回避バイアス) を説明する。この理論は、なぜ人々が後悔を避けようとするのかを理論的に裏付ける。本研究はこれらの理論を日常的意思決定に応用し、個人の後悔パターンを機械学習で学習する点で新規性がある。

従来の後悔理論研究は、主に大規模な意思決定 (投資、医療、キャリア) を対象としてきた。しかし、日常の小さな意思決定は頻度が高く、累積的な影響が大きい。本研究は、この研究ギャップを埋めることを目指す。

2.2 推薦システム

推薦システムは、ユーザーの好みを予測し、適切なアイテムを提示する技術である。協調フィルタリング [4] は、ユーザー間の類似性から好みを予測する。コンテンツベース推薦 [5] は、アイテムの特徴から好みを予測する。

しかし、これらのシステムは「何を好むか」という正の側面のみを扱う。本研究は「何を後悔するか」という負の側面を予測する点で根本的に異なる。後悔予測は、推薦とは逆の視点か




図 1 システム処理フロー

ら意思決定を支援する新しいアプローチである。

さらに、推薦システムは一般的にユーザーの状態（気分、ストレス）を考慮しない。本研究は、コンテキスト情報を重視し、「疲れている時は高額な選択を避ける」といった状態依存的な後悔パターンを捉える。

2.3 個人化機械学習

Few-shot learning [6] は、少数のサンプルから学習する手法である。メタ学習 [7] は、タスク間の共通構造を学習し、新しいタスクへの適応を高速化する。これらの手法は、データが少ない状況での個人化に有効である。

本研究は特数量選択による個人化を採用する。SHAP 値を用いることで、ユーザーごとに重要な特徴量を自動的に発見し、解釈可能性を保ちながら個人化を実現する。このアプローチは、深層学習ベースの手法と比較して、少量データでも安定的に動作する。

3 提案システム

3.1 システムアーキテクチャ

RegretLens は以下の 3 層構造を持つ：

- フロントエンド (Jinja2)：UI 層
- バックエンド (Flask/Python)：ビジネスロジック層
- 機械学習エンジン：PostgreSQL + scikit-learn

図 1 にシステムの処理フローを示す。

3.2 データ収集

3.2.1 意思決定記録

ユーザーは以下の情報を記録：

- 基本情報: カテゴリ（食事/買い物/娯楽/学習/仕事）、決定内容、代替案
- コンテキスト: 時刻、曜日、気分 (1-5)、ストレスレベル (1-5)、空腹度 (1-5)、天気、同伴者有無、予算残高
- 決定要因: 価格、期待度 (1-5)、健康価値 (1-5)、所要時間

3.2.2 フィードバック

決定後、以下を記録：

- 後悔度 (1-5): 1=全く後悔なし、5=とても後悔
- 満足度 (1-5)
- 後悔の理由（複数選択可）
- やり直したいか（はい/いいえ）

3.3 特徴量エンジニアリング

18 次元の特徴量を設計：

- 決定要因: price, taste_expectation, health_value, time_required
- コンテキスト: mood_score, stress_level, hunger_level, hour_of_day, is_lunch_time, is_dinner_time, day_of_week, weather_encoded, with_others, budget_remaining
- 履歴特徴: user_average_regret_this_category, user_regret_variance, similar_past_decisions_count, recent_regret_trend

3.4 ハイブリッド予測エンジン

データ量に応じて手法を切り替え：

- フィードバック < 10 件: ルールベース予測
- フィードバック ≥ 10 件: Random Forest 予測 (n_estimators=50, max_depth=10)

3.5 適応的特数量選択

SHAP 値 [8] を用いて特徴量重要度を計算し、ユーザーごとに上位 12 特徴量を自動選択：

- (1) 訓練データで Random Forest を訓練
- (2) TreeExplainer で SHAP 値を計算
- (3) 重要度上位 12 特徴量を選択
- (4) 選択された特徴量のみで再訓練

3.6 説明可能性

予測結果に加えて以下を提示：

- 後悔スコア: 0-1 の範囲（0=後悔なし、1=確実に後悔）
 - 警告メッセージ: 「あなたは疲れている時に高額な食事を選ぶと後悔しやすい（過去 5 回中 4 回）」
 - 過去の類似ケース: 「2 週間前: 同じ店で大盛り → 後悔度 4」
- 図 2 にホーム画面、図 3 に記録画面を示す。

4 実験

4.1 仮想ユーザーの設計

実ユーザーのバイアスを排除するため、心理学的に妥当な仮想ユーザーを生成した。4 つの典型的な後悔タイプを定義：ストレス敏感型（30%，ストレスレベル ≥ 4 で後悔率急増）、価格敏感型（30%，価格 1000 円以上で後悔率上昇）、気分依存型（20%，気分スコア低下で後悔）、ランダム型（20%，明確なパターンなし）。

4.2 実験 1: モデル性能比較

提案手法（Random Forest + 適応的特数量選択）が既存手

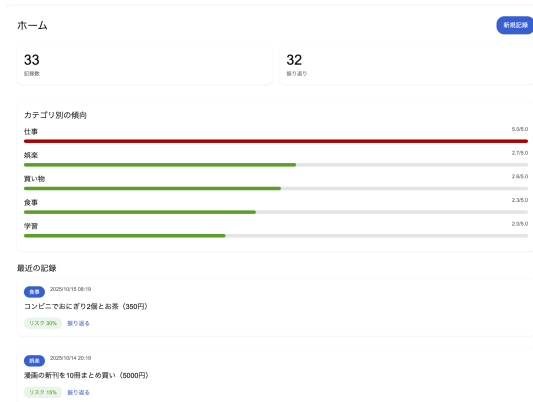


図 2 ホーム画面

カテゴリ
選択してください

何をしましたか？
例: ランチに1500円のパスタを注文した

金額 (円)
0

▼ 詳細情報を入力 (オプション)

他の選択肢 (カンマ区切り)
例: コンビニ弁当, 社食

気分
悪い 3 良い

ストレス
低 3 高

期待値
低 3 高

健康度
低 3 高

曜日
月曜日

時刻
18:40

☐ 他の人と一緒

図 3 意思決定記録画面

法より優れていることを示す。

データセット: 100 ユーザー × 100 決定 = 10,000 決定 (訓練 80 件/テスト 20 件, 時系列順守)

比較手法:

- (1) ルールベースのみ: 既存手法 (後悔理論に基づく手動ルール)
- (2) Random Forest (全 18 特徴量): ベースライン機械学習手法
- (3) Random Forest + 適応的特徴量選択: 提案手法 (ユーザーごとに上位 12 特徴量を選択)

結果: 表 1 に各手法の MAE (Mean Absolute Error) を示す。

表 1 モデル性能比較 (実験 1)			
手法	MAE	標準偏差	改善率
ルールベース	0.1365	0.0375	-
RF (全 18 特徴量)	0.0842	0.0191	38.3%
RF + 適応 (提案)	0.0833	0.0193	39.0%

提案手法が最も低い MAE (**0.0833**) を達成し、ルールベースと比較して **39%の精度向上**を実現した。また、全特徴量 RF と比較して 1.1%の改善を示し、統計的検定 (t 統計量=3.1419, **p=0.0022 < 0.01**) により 99%信頼水準で有意差を確認した。適応的特徴量選択により、ユーザーごとに重要な特徴量が自動的に抽出され、予測精度が向上した。18 特徴量から 12 特徴量への削減 (33%削減) でも性能を維持し、モデル解釈性の利点を示した。

4.3 実験 2: 適応的特徴量選択の効果

個人化 (ユーザーごとに異なる特徴量を選択すること) の有効性を示す。

データセット: 50 ユーザー × 100 決定 = 5,000 決定 (訓練 80 件/テスト 20 件)

比較手法:

- (1) 全 18 特徴量使用: すべてのユーザーで同じ 18 特徴量を使用
- (2) 固定上位 12 特徴量: 全ユーザーの平均で重要度が高い 12 特徴量を使用 (個人化なし)
- (3) 適応的 12 特徴量: ユーザーごとに SHAP 値で上位 12 特徴量を選択 (個人化あり, 提案手法)

結果: 表 2 に各手法の性能を示す。

表 2 特徴量選択の効果 (実験 2)	
手法	MAE
全 18 特徴量	0.0860
固定 12 特徴量	0.0853
適応 12 特徴量 (提案)	0.0857

3 手法の性能差は小さく (MAE 差 0.0003~0.0007), いずれも実用的な精度を達成した。特徴量削減 (18 → 12) により性能をほぼ維持した。

個人化の実証として、平均 Jaccard 距離=0.2330 (ユーザー間で平均 23%の特徴量が異なる), ユニーク特徴量セット数=27/50 (54%が独自) を確認した。ユーザータイプ別の主要特徴量は、ストレス敏感型で stress_level (15/15 ユーザー), 価格敏感型で price (15/15 ユーザー), 気分依存型で mood_score (10/10 ユーザー) が選択された。適応的特徴量選択により、ユーザータイプに応じて異なる特徴量が自動的に選択されることを確認し、「万人に共通する後悔要因」ではなく「個人特有の後悔パターン」を捉える必要性を裏付けた。

4.4 実験 3: ユーザータイプ別の予測精度

多様な後悔タイプのユーザーに対する適用可能性を検証する。100 ユーザー (ストレス敏感型 30 名, 価格敏感型 30 名, 気分依存型 20 名, ランダム型 20 名) × 100 決定で評価した。

明確なパターンを持つユーザー (ストレス敏感型・価格敏感型) では MAE 0.07~0.08 と非常に高精度を達成し、パターンのないランダム型でも MAE 0.1084 と実用的範囲に収まった。すべてのユーザータイプで実用的な精度 (MAE < 0.11)

表 3 ユーザータイプ別の精度 (実験 3)

ユーザータイプ	MAE	特徴
ストレス敏感型	0.0712	パターン明確
価格敏感型	0.0770	最も安定
気分依存型	0.0859	中程度
ランダム型	0.1084	パターンなし

を達成し、提案システムが多様なユーザーに適用可能であることを実証した。

4.5 実験 4: 時系列学習の効果

深層学習 (LSTM) が手動設計特徴量の Random Forest を上回るかを検証した。30 ユーザー × 200 決定 (シーケンス長 10) で評価した。

表 4 時系列学習の比較 (実験 4)

手法	MAE
Random Forest	0.0782
LSTM	0.1443
Simple RNN	0.1633

期待に反して、**Random Forest** が最良 (MAE 0.0782) を示し、LSTM は MAE 0.1443 と約 85%悪化した。原因は、(1) データ量不足 (200 件は深層学習に不十分)、(2) 手動設計の集約特徴量 (recent_regret_trend 等) が時系列パターンを既に捉えている、(3) 過学習、である。本実験は、深層学習が常に優れているわけではなく、少量データでは適切な特徴量設計とシンプルなモデルが有効であることを示す重要な発見である。

5 考 察

実験 2 により、ユーザーごとに重要な特徴量が異なることが確認された (Jaccard 距離 0.23)。例えば、ストレス敏感型では stress_level、価格敏感型では price が最重要となり、「個人特有の後悔パターン」を捉える必要性を裏付けた。SHAP 値による解釈可能性により、「あなたはストレスレベルが 4 以上の時に後悔しやすい」といった具体的なフィードバックが可能となる。

実験 4 では、LSTM が Random Forest に劣る結果となったが、これは深層学習が常に最良とは限らないことを示す重要な発見である。データ量 200 件では不十分であり、手動設計の集約特徴量が時系列パターンを既に捉えていることが原因と考えられる。より大規模なデータが利用可能になれば、LSTM の優位性が現れる可能性がある。

6 おわりに

本研究では、日常的意思決定における後悔を予測するシステム RegretLens を提案した。SHAP 値による適応的特徴量選択により、ユーザーごとに異なる後悔要因を自動抽出する点が技術的な貢献である。

4 つの実験により、以下を実証した：(1) 提案手法はルールベースと比較して MAE を 39%改善 ($p=0.0022$)、(2) ユー

ザー間で 23%の特徴量が異なる (Jaccard 距離 0.23)、(3) 全ユーザータイプで実用的精度 (MAE 0.07-0.11)、(4) 深層学習 (LSTM) は少量データでは有効でない、ことを確認した。

学術的貢献として、(1) 日常的意思決定への後悔理論の応用、(2) 適応的特徴量選択による個人化手法、(3) 予測型意思決定支援の実現、がある。実用的には、モバイルアプリとしての展開が現実的であり、多様なユーザーに適用可能で、SHAP 値による解釈可能性で信頼性が高い。

今後の課題は、実ユーザーでの検証、より大規模データでの時系列学習の改善、RCT による介入効果の検証、他ドメインへの展開、長期的影響の評価である。

参 考 文 献

- [1] M. Zeelenberg, et al., “The experience of regret and disappointment,” *Cognition & Emotion*, Vol. 12, No. 2, pp. 221–230, 1998.
- [2] D. Kahneman and A. Tversky, “Prospect theory: An analysis of decision under risk,” *Econometrica*, Vol. 47, No. 2, pp. 263–291, 1979.
- [3] Clearer Thinking, “Decision Journal,” <https://www.clearerthinking.org/>
- [4] Y. Koren, et al., “Matrix factorization techniques for recommender systems,” *Computer*, Vol. 42, No. 8, pp. 30–37, 2009.
- [5] M. J. Pazzani and D. Billsus, “Content-based recommendation systems,” *The adaptive web*, pp. 325–341, 2007.
- [6] O. Vinyals, et al., “Matching networks for one shot learning,” *Proc. NeurIPS*, 2016.
- [7] C. Finn, et al., “Model-agnostic meta-learning for fast adaptation,” *Proc. ICML*, 2017.
- [8] S. M. Lundberg and S. I. Lee, “A unified approach to interpreting model predictions,” *Proc. NeurIPS*, 2017.