

特徴量選択を用いた日常的意思決定 における個人化後悔予測システム

乾映之右 石橋直樹

武蔵野大学データサイエンス学部データサイエンス学科

背景と問題設定

【背景】

- 日常の小さな意思決定（ランチ、買い物など）で後悔することは多い
- 既存の後悔予測研究は投資・医療など大規模決定のみ対象
- 個人の行動パターンに基づく「後悔の事前予測」は未開拓

【提案】

- 日常の意思決定に特化した後悔予測システム
- 機械学習 + 適応的特徴量選択で個人の後悔パターンを学習
- 意思決定時点で後悔リスクを予測・警告

- 1： 個人の後悔はコンテキスト情報を含む特徴量から機械学習で予測可能か
- 2： 後悔要因の個人差を特徴量選択で明らかにできるか
- 3： MLベース予測はルールベースに対しどの程度の精度差を生じるか

関連研究と位置づけ

既存の後悔予測研究との比較

研究領域	代表的手法	対象	本研究との差異
投資後悔予測	Prospect Theory ベースモデル	金融意思決定	大規模決定のみ 日常場面は対象外
推薦システム	協調フィルタリング コンテンツベース	商品選択支援	後悔予測なし 購買後の分析のみ
感情分析	BERT / LLM センチメント分類	テキスト感情推定	事後分析が中心 事前予測が困難
行動経済学	ホットステート理論 フレーミング効果	認知バイアス研究	理論的枠組のみ 予測システム未実装


本研究の位置づけ： 日常的意思決定に特化 × ML事前予測 × 個人適応

本研究の貢献

項目	内容	技術的ポイント
18次元特徴量空間	決定要因・コンテキスト・時間・ユーザー履歴の4カテゴリ統合設計	行動経済学のホットステート理論に基づく設計
ハイブリッド予測	ML (Random Forest) + ルールベース切替	コールドスタート対応 10件未満→ルール適用
適応的特徴量選択	SHAP等4手法による 個人最適化 (18→12次元)	個人ごとに重要な特徴量を 自動選択・不要次元を除去
時系列CV評価	TimeSeriesSplit + RRR指標による実用効果測定	データリーケージを防止 t検定で有意性検証

→ 日常的意思決定の後悔予測に特化

手法の全体像




設計原則

原則	理由	実装
個人独立モデル	後悔パターンには大きな個人差がある	ユーザーごとにRFモデルを訓練
コールドスタート対応	初期段階でもサービス提供が必要	ルールベースから自動移行
継続的学習	時間経過で後悔パターンが変化	フィードバックループで再訓練
説明可能性	ユーザーの信頼獲得が不可欠	SHAP値で予測根拠を提示

システムアーキテクチャ

Flask + PostgreSQL + scikit-learn + XGBoost + SHAP



データフロー



学習ループ

フィードバック収集 → モデル再訓練 → 予測精度向上 → さらにフィードバック

- ・ フィードバック10件以上でルールベース → ML自動移行
- ・ 新データ追加時に特徴量重要度を再計算

データモデル

【基盤テーブル】

テーブル	主要カラム	説明
decisions	category, text, alternatives, context(JSONB)	意思決定記録
feedbacks	regret_score(1-5 CHECK), satisfaction, would_change	フィードバック
regret_patterns	pattern_type, trigger_conditions, avg_regret	パターン蓄積

【研究用拡張テーブル（6テーブル）】

テーブル	目的
model_performance	モデル精度記録（MAE, RMSE, R^2 , Accuracy）
feature_importance	特徴量重要度の経時変化
experiments	実験条件・パラメータ・結果の管理
prediction_explanations	SHAP値に基づく予測根拠の保存

特微量設計 ① 決定要因 + コンテキスト

18次元の特微量空間（4カテゴリ）

カテゴリ	特微量	次元	値域・説明
決定要因	price		金額（円）：意思決定のコスト
	taste_expectation		味の期待値 (1-5): 選択肢への期待
	health_value, time_required	4	健康価値 / 所要時間
コンテキスト	mood_score		気分 (1-5): 意思決定時の感情状態
	stress_level		ストレス (1-5): ★ ホットステート指標
	hunger_level		空腹度 (1-5): ★ ホットステート指標
	budget_remaining, with_others	5	残り予算 / 同伴者の有無

★ $stress + hunger$ = ホットステート指標（行動経済学: 生理的覚醒が判断を歪める）

特徴量設計 ② 時間 + ユーザー履歴

カテゴリ	特徴量	次元	説明
時間	hour_of_day, is_lunch_time(11-13時), is_dinner_time(18-20時), day_of_week, weather_encoded	5	時間帯・曜日・天気 食事時間帯フラグ
ユーザー 履歴	avg_regret_category, regret_variance, similar_decisions, recent_trend	4	カテゴリ別平均後悔度 分散・類似度・傾向

データリークage防止: 各意思決定より過去のデータのみで履歴特徴量を計算


予測モデル ① MLモデル

Random Forest Regressor

個人ごとに独立モデルを訓練（最低10件のフィードバックで開始）

パラメータ	値	理由
n_estimators	50	個人データ数十件に適したサイズ
max_depth	10	過学習抑制と表現力のバランス
前処理	StandardScaler	ゼロ平均・単位分散に正規化
出力正規化	(score-1)/4	regret_score(1-5) → 0～1に変換

訓練フロー



予測モデル ② ルールベースフォールバック

フィードバック < 10件 → 自動適用（コールドスタート対応）

重み付き加算スコアリング（ベーススコア: 0.3）

条件	加算値	条件	加算値
stress ≥ 4	+0.20	cat_regret ≥ 4	+0.25
price > 1000	+0.15	trend ≥ 4	+0.15
taste ≤ 2	+0.20	mood ≤ 2	+0.10
hunger = 5	+0.15	budget < price	+0.20

リスクレベル分類

高リスク ≥ 0.7

強い警告を表示

中リスク ≥ 0.4

注意喚起を提示

低リスク < 0.4

通常的意思決定


例: $base(0.3) + stress \geq 4(+0.20) + price > 1000(+0.15) = 0.65 \rightarrow$ 中リスク

適応的特徴量選択

18次元 → 12次元に自動絞り込み（個人ごとに最適なサブセット）

手法	概要	特性
SHAP値	TreeExplainerでShapley値を計算	正負の貢献方向を可視化
Permutation Importance	特徴量シャッフルで性能低下量を測定	n_repeats=10, モデル非依存
RFE	再帰的特徴量除去	相互作用考慮、計算コスト高
SelectKBest	F回帰統計量でフィルタリング	計算軽量、初期スクリーニング

選択アルゴリズム



パターン検出と警告生成

4種のパターン検出（最低2回以上の出現で登録）

パターン	検出条件	例
高ストレス時	stress $\geq$ 4 かつ regret $\geq$ 4	疲れている時の食事選択
高額購入時	price > 1000 かつ regret $\geq$ 3	衝動買いの後悔
低期待値	taste_exp $\leq$ 2 かつ regret $\geq$ 3	妥協した選択での後悔
曜日別	曜日×カテゴリで regret $\geq$ 4	金曜夜の外食パターン

警告例:「あなたは疲れている時に食事で後悔しやすい傾向があります（過去3回）」


+ 類似ケースを最大3件表示（日付・内容・スコア・理由）

実装の詳細

主要APIエンドポイント (Flask RESTful)

エンドポイント	メソッド	機能	レスポンス
/api/predict	POST	後悔リスク予測	score, risk_level, warnings
/api/feedback	POST	フィードバック登録+再訓練	updated_model_info
/api/patterns	GET	後悔パターン一覧取得	patterns[], similar_cases[]
/api/evaluate	POST	モデル評価・比較実験	metrics{}, comparison{}
/api/features	GET	特徴量重要度取得	shap_values, rankings


技術スタック



評価フレームワーク ① 交差検証

時系列交差検証 (TimeSeriesSplit)

n_splits = 5 (データ量に応じて動的調整)



比較モデル

モデル	パラメータ
提案手法 (RF+SHAP)	n_estimators=50, max_depth=10 + SHAPによる特徴量選択 (18→12次元)
Random Forest	n_estimators=50, max_depth=10 全18特徴量使用
ルールベース	重み付き加算スコアリング (ベース: 0.3)

評価フレームワーク ② 評価指標

種別	指標	説明
回帰	MAE	平均絶対誤差
	RMSE	二乗平均平方根誤差
	R ²	決定係数
分類	Accuracy / Precision	3クラス: 高(≥ 0.7) / 中(≥ 0.4) / 低(< 0.4)
	Recall / F1	macro平均で算出

Regret Reduction Rate (RRR)

$$\text{RRR} = (\text{avg_before} - \text{avg_after}) / \text{avg_before}$$

システム導入前後の平均後悔度の変化率 → t検定で有意性検証 ($p < 0.05$)

予備実験結果

33件 decisions / 32件 feedbacks / 5カテゴリ / 2ヶ月間 / 5-fold 時系列交差検証

モデル比較

	MAE	RMSE	R ²
提案手法 (RF+SHAP)	0.0946	0.1129	0.334
Random Forest	0.1024	0.1229	0.223
ルールベース	0.1400	0.1565	-0.960

SHAP 特徴量重要度 Top5

#	特徴量	SHAP値
1	stress_level	0.1036
2	price	0.0230
3	avg_regret_category	0.0172
4	regret_variance	0.0115
5	taste_expectation	0.0090
...	weather, is_dinner_time, etc.	< 0.003

※ ダミーデータによる予備評価

SHAP分析と特徴量重要度

TreeExplainer によるSHAP値算出 → 個人ごとの後悔要因を可視化

順位	特徴量	SHAP寄与方向	解釈
1	stress_level	高ストレス → 後悔↑	最も強い予測因子
2	avg_regret_category	過去高後悔 → 後悔↑	カテゴリ別の傾向反映
3	price	高価格 → 後悔↑	金額と後悔の正の相関
4	hunger_level	高空腹 → 後悔↑	ホットステート影響
5	taste_expectation	高期待 → 後悔↓	期待値と後悔の負の相関
...	weather_encoded	影響小	除去候補（選択で除外）

分析から得られた知見

ホットステート理論の検証

stress + hunger がトップ要因

個人履歴の有効性

avg_regret が2位 → 履歴重要

不要特徴量の特定

weather等は除去可能 → 12次元

考察と制限事項

設計上の強み

個人独立モデル	個人差の大きい後悔予測に適合 → 汎用モデルでは捉えられない個人特性
ハイブリッド	データ不足期はルールベース → 蓄積後MLに自動移行
SHAP解釈性	なぜその予測かを説明可能 → ユーザーの信頼構築
パターン検出	4種の後悔パターンを自動検出 → 類似ケースで具体的に警告

制限事項と対応策

シングルユーザー	FIXED_USER_ID設計 → マルチユーザー拡張を計画
自己申告バイアス	後知恵バイアスの影響 → 時間的遅延の最小化で緩和
データ量制約	最低10件のフィードバック必要 → ルールベースでの初期対応
長期検証未実施	長期RRR変化が未検証 → 6ヶ月間の縦断研究を計画

→ 制限事項はあるが、日常的意思決定における後悔予測の実現可能性を示した

今後の展望

現行版

```
graph TD; A[現行版] --> B[マルチユーザー対応]; A --> C[時系列モデル導入]; A --> D[反実仮想説明の強化];
```

マルチユーザー対応

協調フィルタリング導入
類似ユーザーの知見活用
コールドスタート問題の緩和

時系列モデル導入

LSTM / GRU による
意思決定遷移パターン捕捉
長期的な後悔傾向の予測

反実仮想説明の強化

「もしストレスが低ければ」
→ スコア変化を提示
ユーザー理解の促進

結論

研究課題への回答

RQ	問い	回答・知見
RQ1	コンテキスト情報を含む特徴量から後悔は予測可能か	18次元特徴量でMLモデルが ルールベースを上回る精度を達成
RQ2	個人差を適応的特徴量選択で 定量化できるか	SHAP分析で個人ごとの重要特徴量を 特定、18→12次元で精度維持
RQ3	ML vs ルールベースの 精度差はどの程度か	MAE, RMSE とともにRFが優位 特に履歴特徴量追加で大幅改善

新規性

日常的意思決定の後悔予測に
特化した統合フレームワーク

実用性

コールドスタート対応の
ハイブリッド設計で即座に提供

再現性

オープンソース実装
時系列CVでリークage防止

まとめ

日常の意思決定における後悔を事前に予測するシステム

要素	本研究のアプローチ	成果
特徴量設計	18次元（決定要因+コンテキスト+時間+履歴）	行動経済学に基づく設計
予測モデル	RF + ルールベースハイブリッド	コールドスタート対応
特徴量選択	SHAP等4手法で18→12次元	個人最適化を実現
評価	時系列CV + RRR指標	リーケージ防止を保証

予備実験結果

MLモデルがルールベースを上回る予測精度を達成 → 18次元特徴量の有効性を確認